

# 中国科学技术大学



## 数据分析及实践 金融大数据分析调研报告

作者姓名: Xiaoma

专业领域: 数据科学与大数据技术

授课教师: 刘淇教授

完成时间: 二〇二三年五月十九日



## 摘 要

定量交易和投资决策是复杂的金融任务，依赖于准确的股票选择，深度学习的最新发展推动了机器学习辅助股票交易策略的深入研究。但一方面，由于模型的不确定性，在随机股票数据上以端到端方式训练股票表示可能会导致过度建模，泛化能力较弱，阻碍了典型的数据密集型机器学习方法的应用；另一方面，股票数据与其相关因素的关联分析涉及到数据的不确定性。因此确保更好的样本效率和鲁棒性非常重要。

本文选择 **AAAI 2021** 中有关量化交易的四篇文章，深度分析了其对应的模型原理以及最终表现，了解了现阶段量化交易对数据与模型不确定性的处理方法，并做出一些探索性思考。

**关键词：**数据挖掘    量化交易    数据降维

# 目 录

第 1 章 预备知识	1
1.1 数学基础	1
1.1.1 奇异值分解	1
1.1.2 主成分分析	1
1.1.3 对数差分	1
1.1.4 卷积	2
1.1.5 copula 函数	2
1.2 金融基础	2
1.2.1 对冲	2
1.2.2 做空	3
1.2.3 做多	3
1.2.4 常用评价指标	4
1.3 机器学习模型概述	5
1.3.1 线性模型	5
1.3.2 决策树	6
1.3.3 支持向量机	6
1.3.4 集成学习	6
1.3.5 神经网络	7
1.4 深度学习基础	7
1.4.1 图卷积神经网络	7
1.4.2 长短期记忆递归神经网络	7
1.5 强化学习基础	8
1.5.1 随机博弈	8
1.6 超图	8
第 2 章 剔除宏观市场因素的金融大数据分析	9
2.1 基于残差因子分布预测的深度投资组合优化	9
2.1.1 残差因子的提取	9
2.1.2 评价指标与网络结构的建立	10
2.1.3 结果评估	11
2.2 基于时空超图注意网络的股票选择: 一种学习排序方法	12
2.2.1 模型结构	12

2.2.2	股价时序特征提取	12
2.2.3	股票空间超图构建	14
2.2.4	结果评估	16
第 3 章	引入宏观市场因素的金融大数据分析	17
3.1	耦合宏观-行业-微观金融指标的低不确定性股票表征学习	17
3.1.1	编码器-解码器结构	17
3.1.2	宏观行业背景学习	18
3.1.3	股票表征学习	20
3.1.4	结果评估	21
3.2	嵌入市场条件的风险收益平衡投资管理的深度强化学习方法	21
3.2.1	模型结构	22
3.2.2	资产评估单元	22
3.2.3	市场评估单元	24
3.2.4	投资组合生成器	24
3.2.5	结果评估	25
第 4 章	探索性思考	26
参考文献		27
致谢		29



## 第1章 预备知识

### 1.1 数学基础

#### 1.1.1 奇异值分解

奇异值分解（Singular Value Decomposition，以下简称 SVD）是一种矩阵分解的方法，可以将一个矩阵分解为三个矩阵的乘积，即。

$$A = U \Sigma V^T$$

其中， $U$  和  $V$  是正交矩阵， $\Sigma$  是对角矩阵。

奇异值分解的意义在于，它可以将一个比较复杂的矩阵用更小更简单的几个子矩阵的相乘来表示，这些小矩阵描述的是矩阵的重要的特性。这种分解方法可以帮助我们更好地理解数据，从而更好地进行数据处理和分析。

#### 1.1.2 主成分分析

主成分分析（PCA）是一种常见的数据分析方式，常用于高维数据的降维，可用于提取数据的主要特征分量。主成分分析的原理是设法将原来变量重新组合成一组新的相互无关的几个综合变量，同时根据实际需要从中可以取出几个较少的总和变量尽可能多地反映原来变量的信息的统计方法叫做主成分分析或称主分量分析，也是数学上处理降维的一种方法。

PCA 的降维过程为：

1. 设有  $n$  个样本，每个样本有  $p$  个特征
2. 样本矩阵为  $X_{n \times p}$
3. 样本均值为  $\bar{x}$
4. 中心化后的样本矩阵为  $Z = X - \bar{x}$
5. 计算协方差矩阵  $C = \frac{1}{n-1} Z^T Z$
6. 计算协方差矩阵的特征值和特征向量  $C\alpha = \lambda\alpha$
7. 将特征值从大到小排序，选择前  $k$  个特征向量组成变换矩阵  $P = [\alpha_1, \dots, \alpha_k]$
8. 对样本进行降维处理，得到新的  $k$  维样本矩阵  $Y = ZP$

#### 1.1.3 对数差分

对数差分是一种常用的时间序列预处理方法，它可以将非平稳的时间序列转化为平稳的时间序列。对数差分的数学原理是先对时间序列取对数，然后再进行差分。这样做的好处是可以消除时间序列的趋势和季节性变化，使得时间序列更加平稳，更容易进行建模和预测。

### 1.1.4 卷积

卷积是一种数学运算，它是两个函数之间的一种操作，通常用于信号处理和图像处理中。卷积的数学原理可以用公式表示，如下所示：

$$(f * g)(t) = \int_{-\infty}^{\infty} f(\tau)g(t - \tau)d\tau$$

其中， $f(t)$  和  $g(t)$  是两个函数， $*$  表示卷积运算符。卷积的本质是将一个函数与另一个函数进行加权平均，其中第二个函数是翻转并平移的。卷积的物理意义是在时域上对两个信号进行加权平均，以获得它们之间的相似性。

### 1.1.5 copula 函数

Copula 函数是定义域为  $[0, 1]$  均匀分布的多维联合分布函数，其核心概念是以 Copula 函数将多个随机变量的边缘分布耦合起来。

一般情况下， $n$  元 copula 函数  $C : [0, 1]^n \rightarrow [0, 1]$  是多元联合分布

$$C(u_1, u_2, \dots, u_n) = P(U_1 \leq u_1, U_2 \leq u_2, \dots, U_n \leq u_n)$$

其中  $U_1, U_2, \dots, U_n$  是标准均匀分布

Copula 函数能够把随机变量之间的相关关系与变量的边际分布分开进行研究，这种思想方法在多元统计分析中非常重要。

## 1.2 金融基础

### 1.2.1 对冲

**对冲、套期保值**是一个金融学术语，只特意降低另一项投机风险的投资。它是一种在降低商业风险的同时仍然能在投资中获利的手法。一般对冲是同时进行两笔行情相关、方向相反、数量相当、盈亏相抵的交易。行情相关是指两种商品价格行情的市场供求关系存在统一性，供求关系若发生变化，同时会影响两种商品的价格，且价格变化的方向大体一致。方向相反指两笔交易的买卖方向相反，这样无论价格向什么方向变化，总是一盈一亏，作用在于减低另一项投资的风险的投资，但如果判断错误，损失可能会超过未进行“对冲时大”。

常见的对冲模式：

- **股指期货对冲**

股指期货对冲是指利用股指期货市场存在的不合理价格，同时参与股指期货与股票现货市场交易，或者同时进行不同期限、不同（但相近）类别股票指数合约交易，以赚取差价的行为。股指期货套利分为期现对冲、跨期对冲、跨市对冲和跨品种对冲。



- **商品期货对冲**与股指期货对冲类似，商品期货同样存在对冲策略，在买入或卖出某种期货合约的同时，卖出或买入相关的另一种合约，并在某个时间同时将两种合约平仓。在交易形式上它与套期保值有些相似，但套期保值是在现货市场买入（或卖出）实货、同时在期货市场上卖出（或买入）期货合约；而套利却只在期货市场上买卖合约，并不涉及现货交易。商品期货套利主要有期现对冲、跨期对冲、跨市场套利和跨品种套利 4 种
- **统计对冲**有别于无风险对冲，统计对冲是利用证券价格的历史统计规律进行套利的，是一种风险套利，其风险在于这种历史统计规律在未来一段时间内是否继续存在。统计对冲的主要思路是先找出相关性最好的若干对投资品种（股票或者期货等），再找出每一对投资品种的长期均衡关系（协整关系），当某一对品种的价差（协整方程的残差）偏离到一定程度时开始建仓——买进被相对低估的品种、卖空被相对高估的品种，等到价差回归均衡时获利了结即可。统计对冲的主要内容包括股票配对交易、股指对冲、融券对冲和外汇对冲交易。
- **期权对冲**期权（Option）又称选择权，是在期货的基础上产生的一种衍生性金融工具。从其本质上讲，期权实质上是在金融领域将权利和义务分开进行定价，使得权利的受让人在规定时间内对于是否进行交易行使其权利，而义务方必须履行。在期权的交易时，购买期权的一方称为买方，而出售期权的一方则称为卖方；买方即权利的受让人，而卖方则是必须履行买方行使权利的义务人。期权的优点在于收益无限的同时风险损失有限，因此在很多时候，利用期权来取代期货进行做空、对冲利交易，会比单纯利用期货套利具有更小的风险和更高的收益率。

### 1.2.2 做空

**做空**是一种金融交易手段，其具体策略是做空者预期股票期货市场会有下跌趋势，借入股票后立即将其出售。做空者最后必须将这些股票归还给借贷方（且需要加上利息）。因此若能正确预测股票期货下跌，空方在下跌后再重新买入股票期货并归还，即可获利，理论上是先借货卖出，再买进归还。

### 1.2.3 做多

**做多**也是一种金融交易手段，其具体交易策略与**做空**相反，即看好股票、外汇或期货等未来的上涨前景而进行买入持有等待上涨获利后卖出，理论上是先买后卖。

### 1.2.4 常用评价指标

- **夏普比率**：夏普比率（Sharpe Ratio）是一种衡量投资回报与风险之间关系的指标。它的定义是投资收益与无风险收益之差的期望值，再除以投资标准差（即其波动性）。夏普比率越大越好，夏普比率小于零说明策略的平均收益率为负，夏普比率小于 1 说明策略的风险大于收益。

$$SR = \frac{E[R_a - R_b]}{\sigma_a} = \frac{E[R_a - R_b]}{\sqrt{\text{var}[R_a - R_b]}}$$

其中， $R_a$  是资产收益， $R_b$  是无风险收益（如美国国库证券）， $E[R_a - R_b]$  是资产收益超出基准收益的期望值， $\sigma_a$  是资产收益超额的标准差。

- **Beta** Beta 是一种衡量投资组合相对于市场整体波动性的指标。它代表了投资组合表现对大盘变化的敏感性，也即是投资组合与大盘的相关性。例如，如果一个投资组合的 Beta 为 1.5，则大盘涨 1% 的时候，投资组合可能涨 1.5%，反之亦然；如果一个投资组合的 Beta 为 -1.5，说明大盘涨 1% 的时候，投资组合可能跌 1.5%，反之亦然。

$$\text{beta} = \frac{\text{Cov}(r_p, r_b)}{\text{Var}(r_b)}$$

其中， $r_p$  是投资组合收益率， $r_b$  是基准收益率（如上证指数）， $\text{Cov}(r_p, r_b)$  是投资组合收益率与基准收益率的协方差， $\text{Var}(r_b)$  是基准收益率的方差。

- **Alpha** Alpha 是一种衡量投资组合相对于市场整体波动性的指标。它代表了投资组合的超额收益，与市场波动无关，也就是说不是靠系统性的上涨而获得收益。通过预测方向或者其他可解释原因的策略也即是 alpha 策略；而通过波动率来带来利润的策略就是 beta 策略。

$$\text{alpha} = r_p - [r_f + \text{beta} * (r_b - r_f)]$$

其中， $r_p$  是投资组合年化收益率， $r_b$  是基准年化收益率（如上证指数）， $r_f$  是无风险利率（默认 0.04）， $\beta$  是投资组合的 Beta 值。

- **最大回撤比率**最大回撤是衡量策略风险的重要指标，可理解为可能发生的最大亏损幅度，其值等于策略收益曲线上，高点到后期最低点的回撤幅度的最大值。衡量一个策略风险控制能力，最大回撤是最常用的指标，描述了投资者可能面临的最大的亏损。最大回撤的数值越小越好，越大说明风险越大。

$$MDD = \frac{P_{\max} - P_{\min}}{P_{\max}}$$

其中,  $P_{max}$  是策略收益曲线上的高点,  $P_{min}$  是策略收益曲线上高点后期的最低点。

- 索提诺比率索提诺比率 (Sortino Ratio) 是一种风险调整后的收益指标, 用来衡量投资组合在单位下行风险下所能获得的超额收益。它与夏普比率类似, 但是分母换成了策略收益的下行波动率, 下行波动率就是只计算负的收益率与平均收益率间的标准差, 就是只计算不利的部分波动率。

$$SortinoRatio = \frac{E(R_p) - MAR}{\sqrt{\frac{1}{T-1} \sum_{t=1}^T (R_{p_t} - R_f)^2}}$$

其中,  $E(R_p)$  是资产的期望收益率,  $MAR$  是可接受最低收益 (Minimum Acceptable Return),  $R_p$  是收益列中小于无风险收益的全部样本,  $R_f$  是无风险收益率,  $T$  是样本数量。

### 1.3 机器学习模型概述

机器学习是人工智能的一个分支。人工智能的研究历史有着一条从以“推理”为重点, 到以“知识”为重点, 再到以“学习”为重点的自然、清晰的脉络。显然, 机器学习是实现人工智能的一个途径之一, 即以机器学习为手段, 解决人工智能中的部分问题。

机器学习理论主要是设计和分析一些让计算机可以自动“学习”的算法。机器学习算法是一类从数据中自动分析获得规律, 并利用规律对未知数据进行预测的算法。

常见的机器学习模型有: 线性模型、决策树、支持向量机、集成学习、神经网络、聚类、朴素贝叶斯等。

#### 1.3.1 线性模型

机器学习中的线性模型是一种简单的预测模型, 它假设目标变量是输入特征的线性组合。对于一个有  $d$  个特征的数据集, 线性模型可以表示为:

$$y = w_1x_1 + w_2x_2 + \dots + w_dx_d + b$$

其中  $w_i$  是第  $i$  个特征的权重,  $b$  是偏置项。线性模型的目标是通过最小化损失函数来找到最优的权重和偏置项。

### 1.3.2 决策树

**决策树**是一种常用的监督学习算法，它可以用于解决分类和回归问题。决策树通过递归地将数据集划分为更小的子集来构建一棵树形结构。

在每次划分时，算法会选择一个最优的特征来进行划分。最优特征的选择通常基于信息增益或基尼指数等准则。

信息增益表示划分后数据集的纯度提高了多少。它的计算公式为：

$$\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

其中， $\text{Ent}(D)$  表示数据集  $D$  的熵， $V$  表示特征  $a$  的取值个数， $D^v$  表示数据集  $D$  中特征  $a$  取值为  $v$  的子集。

### 1.3.3 支持向量机

**支持向量机 (SVM)** 是一种常用的监督学习算法，它可以用于解决分类和回归问题。SVM 的目标是找到一个超平面来最大化两个类别之间的间隔。

对于线性可分的数据集，SVM 通过解决以下优化问题来找到最优超平面：

$$\min_{w,b} \frac{1}{2} \|w\|^2 \text{ s.t. } y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, m$$

其中， $w$  是超平面的法向量， $b$  是超平面的截距， $x_i$  是第  $i$  个样本的特征向量， $y_i$  是第  $i$  个样本的类别标签。

对于线性不可分的数据集，SVM 可以通过引入松弛变量和核函数来解决。

### 1.3.4 集成学习

**集成学习**是一种常用的机器学习方法，它通过结合多个弱学习器来构建一个强学习器。常见的集成学习算法包括 Bagging、Boosting 和 Stacking 等。

**Bagging** 算法通过对原始数据集进行有放回抽样来生成多个训练集，然后在每个训练集上训练一个弱学习器，最后对所有弱学习器的预测结果进行投票或平均来得到最终的预测结果。

**Boosting** 算法通过迭代地训练多个弱学习器来构建一个强学习器。在每次迭代中，算法会根据上一轮弱学习器的预测错误率来调整样本的权重，然后在加权的数据集上训练下一个弱学习器。

**Stacking** 算法通过将多个不同的弱学习器的预测结果作为新的特征来训练一个元模型，从而得到最终的预测结果。

### 1.3.5 神经网络

**神经网络**是一种常用的机器学习算法，它由多个层组成，每层包含多个神经元。神经网络通过模拟人脑神经元之间的连接来进行计算。

对于一个有  $L$  层的神经网络，其第  $l$  层的输出可以表示为：

$$a^{(l)} = \sigma(z^{(l)})z^{(l)} = W^{(l)}a^{(l-1)} + b^{(l)}$$

其中， $W^{(l)}$  和  $b^{(l)}$  分别表示第  $l$  层的权重矩阵和偏置向量， $\sigma(\cdot)$  表示激活函数。

神经网络的训练通常采用反向传播算法，它通过计算损失函数关于权重和偏置的梯度来更新参数。

## 1.4 深度学习基础

### 1.4.1 图卷积神经网络

图卷积神经网络（Graph Convolutional Neural Network, GCN）是一种基于图的深度学习模型，它可以处理图数据，如社交网络、化学分子、3D 模型等。

$$\begin{aligned} \mathbf{X}^{(l)} &= \mathbf{H}^{(l-1)} \\ \mathbf{H}^{(l)} &= \sigma(\tilde{\mathbf{D}}^{-\frac{1}{2}} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-\frac{1}{2}} \mathbf{H}^{(l-1)} \mathbf{W}^{(l-1)}) \end{aligned}$$

其中， $\mathbf{X}^{(l)}$  是第  $l$  层的输入特征矩阵， $\mathbf{H}^{(l)}$  是第  $l$  层的输出特征矩阵， $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}$  是邻接矩阵  $\mathbf{A}$  加上自环后的邻接矩阵， $\tilde{\mathbf{D}}_{ii} = \sum_j \tilde{\mathbf{A}}_{ij}$  是度矩阵。 $\sigma(\cdot)$  是激活函数， $\mathbf{W}^{(l-1)}$  是第  $l-1$  层到第  $l$  层的权重矩阵。

### 1.4.2 长短期记忆递归神经网络

LSTM（Long Short-Term Memory）是一种常用的循环神经网络（Recurrent Neural Network, RNN）模型，它可以处理序列数据，如文本、语音、视频等。

$$\begin{aligned} \mathbf{i}_t &= \sigma(\mathbf{W}_{xi}\mathbf{x}_t + \mathbf{W}_{hi}\mathbf{h}_{t-1} + \mathbf{W}_{ci}\mathbf{c}_{t-1} + \mathbf{b}_i) \\ \mathbf{f}_t &= \sigma(\mathbf{W}_{xf}\mathbf{x}_t + \mathbf{W}_{hf}\mathbf{h}_{t-1} + \mathbf{W}_{cf}\mathbf{c}_{t-1} + \mathbf{b}_f) \\ \mathbf{o}_t &= \sigma(\mathbf{W}_{xo}\mathbf{x}_t + \mathbf{W}_{ho}\mathbf{h}_{t-1} + \mathbf{W}_{co}\mathbf{c}_{t-1} + \mathbf{b}_o) \\ \tilde{\mathbf{c}}_t &= \tanh(\mathbf{W}_{xc}\mathbf{x}_t + \mathbf{W}_{hc}\mathbf{h}_{t-1} + \mathbf{b}_c) \\ \mathbf{c}_t &= \mathbf{i}_t * \tilde{\mathbf{c}}_t + \mathbf{f}_t * \mathbf{c}_{t-1} \\ \mathbf{h}_t &= \tanh(\mathbf{o}_t * \tanh(\mathbf{c}_t)) \end{aligned}$$

其中， $\sigma(\cdot)$  是 sigmoid 函数， $\tanh(\cdot)$  是双曲正切函数， $\odot$  是逐元素乘法。

## 1.5 强化学习基础

强化学习（Reinforcement Learning）是一种机器学习方法，它通过智能体（Agent）与环境（Environment）的交互来学习最优策略。在强化学习中，智能体通过观察环境的状态，采取不同的行动，获得奖励或惩罚，从而逐步学习到最优策略。强化学习的应用非常广泛，如游戏、机器人、自动驾驶等领域。

### 1.5.1 随机博弈

随机博弈是一种包含一个或多个参与者进行的具有状态概率转移的动态博弈过程。随机博弈由多个博弈阶段组成。在每一个阶段的开始，博弈处在某个特定状态下。参与者选择自身的策略并获得相应的由当前状态和策略决定的报酬。

下面是一个简单的随机博弈数学描述：

- 有限参与者集  $N$ ；
- 状态空间  $S$ （可以是有限集，也可以是可测空间）；
- 对于每一参与者  $i \in N$ ，存在行动集  $A_i$ （可以是有限集，也可以是可测空间）；
- 是从  $S \times A$  到  $S$  的转移概率，其中  $a \in A = A_1 \times \dots \times A_n$  是行动组合， $p(s'|s, a)$  是下一状态处于  $s' \in S$  中的概率，而给定了当前状态  $s \in S$  和当前行动组合  $a \in A$ ；
- 从  $S \times A$  到  $\mathbb{R}^n$  的收益函数  $r : S \times A \rightarrow \mathbb{R}^n$ ，其中  $r(s, a)_i$  是参与者  $i$  的收益，而  $r(s, a)$  是状态  $s$  和行动组合  $a$  的函数。

## 1.6 超图

超图是一种广义上的图，它的一条边可以连接任意数量的顶点。形式上，超图  $H$  是一个集合组  $H = (X, E)$ ，其中  $X$  是一个有限集合，该集合的元素被称为节点或顶点， $E$  是  $X$  的非空子集的集合，被称为超边或连接。

超图具有许多性质，例如：

- 超边可以同时连接  $\geq 2$  个点
- 超边的建立有许多种方法，可以根据研究的问题特性来进行选择

超图和普通图的主要区别在于它们的边的定义。在普通图中，每条边只能连接两个点，而在超图中，一条边可以连接任意数量的顶点。这种新的边被称为超边（hyperedge）。

## 第2章 剔除宏观市场因素的金融大数据分析

### 2.1 基于残差因子分布预测的深度投资组合优化

组合优化是金融领域中一个重要的问题，它涉及到如何在给定一组资产和一个目标函数的情况下，选择最优的资产权重。传统的组合优化方法通常基于Markowitz 均值-方差模型<sup>[1]</sup>，该模型假设投资者只关心资产收益的均值和方差，并且资产收益服从正态分布。然而，这些假设在实际市场中往往不成立，导致传统方法存在一些局限性，如忽略了高阶矩、过度依赖参数估计、忽略了市场因子等。

为了克服这些局限性，近年来有许多研究尝试利用机器学习技术来辅助组合优化，例如使用神经网络、支持向量机、随机森林等算法来预测资产收益或风险。然而，由于金融市场具有高度的非平稳性和复杂性，导致这些机器学习方法往往需要大量的数据和计算资源，并且容易过拟合或失效。

为了降低金融市场的不稳定性对模型的影响，**Kentaro Imajo** 等人提出了一种基于残差因子提取方法的深度学习模型来构建股票交易策略。




图 2.1 算法结构

#### 2.1.1 残差因子的提取

残差因子是指在去除了常见市场因子（如市场、规模、价值、动量等）影响后，剩余的个股特异性信息。残差因子可以用来对冲市场因子带来的风险因素，并且可以反映个股未来收益的潜力<sup>[2]</sup>。

该算法使用一种新的谱残差方法来提取残差<sup>[3]</sup>。

##### 1. 谱残差

设  $r$  为均值为 0 的随机向量，其协方差为  $\Sigma \in \mathbb{R}^{S \times S}$ ，表示给定投资期限内  $S$  支股票的收益。由于  $\Sigma$  是对称矩阵，对其进行奇异值分解

$$\Sigma = \mathbf{V} \Lambda \mathbf{V}^T$$

其中  $\mathbf{V} = [\mathbf{v}_1, \dots, \mathbf{v}_S]$  是正交矩阵， $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_S)$  是对角矩阵。建立一个新的随机向量  $\hat{r} = \Sigma^T r$  使得对于  $\forall \hat{r}_i \in \hat{r}$  都相互正交。

在投资组合理论中， $\hat{r}$  被称为主要投资组合<sup>[4]</sup>。

为了对冲共同的市场因素，一个自然的想法是放弃几个具有最大特征值的主要投资组合<sup>[3]</sup>。

设正整数  $C < S$ ，定义谱残差为一个向量  $\tilde{\epsilon}$ ，其通过将原始向量  $\mathbf{r}$  投影到具有最小  $S - C$  特征值的主成分张成的空间上得到。

在股票市场中，时效性对于投资是十分重要的，故需要设定一个时间窗口  $H > 1$ ，那么窗口信号为  $\mathbf{X}_t = [\mathbf{r}_{t-H}, \dots, \mathbf{r}_{t-1}]$ ，设  $\tilde{\mathbf{X}}_t = \mathbf{X}_t - E[\mathbf{X}_t]$ ，对其进行奇异值分解得

$$\tilde{\mathbf{X}}_t = \mathbf{V}_t \Sigma_t \mathbf{U}_t$$

其中  $\mathbf{V}_t$  为  $S \times S$  的正交矩阵， $\mathbf{U}_t$  为  $S \times H$  的行正交矩阵， $\sigma_1, \dots, \sigma_S$  为奇异值。

则  $\mathbf{V}_t \tilde{\mathbf{X}}_t$  为考虑时间窗口后的主投资组合，那么设近似矩阵

$$\mathbf{A}_t = \Lambda_t \text{diag}(\underbrace{0, \dots, 0}_C, \underbrace{1, \dots, 1}_{S-C}) \mathbf{V}_t^T$$

最终得到谱残差为

$$\tilde{\epsilon}_s = \mathbf{A}_t \mathbf{r}_s$$

## 2.1.2 评价指标与网络结构的建立

### 1. 评价指标

假设有  $S$  只股票，其价格按照离散时间的分布为  $\mathbf{p}^{(i)} = (p_1^{(i)}, \dots, p_t^{(i)})$ ，其中  $p_t^{(i)}$  为股票在  $t$  时刻的价格，我们关注股票的收益而不是原价，设股票在  $t$  时刻的定义为  $r_t^{(i)} = p_{t+1}^{(i)} / p_t^{(i)}$ 。

定义投资组合是股票与时间相关的权重向量  $\mathbf{b}_t = (b_t^{(1)}, \dots, b_t^{(S)})$ ，其中  $b_t^{(i)}$  为满足  $\sum_{i=1}^S |b_t^{(i)}|$  的股票  $i$  的投资比例，若  $b_t^{(i)} > 0$ ，则表示持有该股票的多头头寸，若  $b_t^{(i)} < 0$ ，则表示持有该股票的空头头寸。

定义投资组合的收益为

$$R_t = \sum_{i=1}^S b_t^{(i)} r_t^{(i)}$$

由于在股票交易过程中，观察到回报和执行交易之间可能有延迟，则考虑延迟因素

$$R_t = \sum_{i=1}^S b_t^{(i)} r_{t+d}^{(i)}$$

### 2. 网络结构

在谱残差的基础上实现一种新颖的神经网络结构，它能够结合一些广泛认可的金融归纳偏置，例如幅度不变性和时间尺度不变性<sup>[3]</sup>。幅度不变性是指网



络的输出不应该受到输入特征的绝对大小的影响，而只应该取决于它们的相对变化。时间尺度不变性是指网络的输出应该在不同的时间尺度上具有一致性，例如日、周或月。

该网络的主要改进为：

- 使用**对数差分**来转换输入特征，从而消除幅度的影响，并捕捉相对变化。
- 使用**多尺度卷积**来处理不同长度的输入序列，并提取多层次的特征。
- 使用**自注意力机制**来增强网络的长期依赖性，并捕捉输入序列中的重要模式。
- 使用**残差连接**来加速网络的收敛，并提高网络的表达能力。
- 使用基于**混合密度网络（MDN）**的分布式预测器，能够预测残差因子的分布，而不仅仅是均值或方差。

最终需要优化的函数为

$$r_t = X_t \beta + \epsilon_t$$

$$\hat{p}(\epsilon_t | X_t) = \text{MDN}(f(X_t; \theta))$$

$$w_t = g(\hat{p}(\epsilon_t | X_t); \lambda)$$

其中  $r_t$  是时间  $t$  的股票收益率向量， $X_t$  是输入特征矩阵， $\beta$  是因子载荷矩阵， $\epsilon_t$  是残差因子向量， $\hat{p}(\epsilon_t | X_t)$  是残差因子的预测分布

### 2.1.3 结果评估

在美国市场将使用与未使用谱残差的收益进行对比，其中参数  $C = 10$

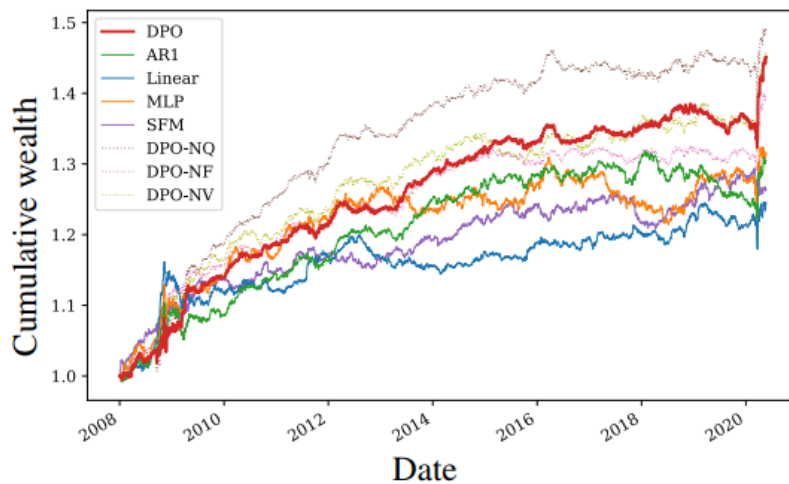


图 2.2 使用谱残差

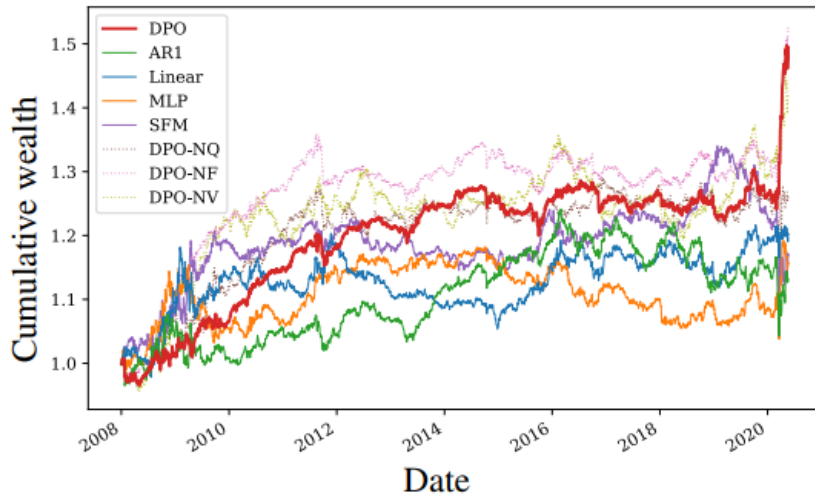


图 2.3 未使用谱残差

## 2.2 基于时空超图注意网络的股票选择: 一种学习排序方法

**Ramit Sawhney** 等人提出了基于时空超图注意网络的学习方法, 通过超图对股票中复杂的关系进行建模, 以及同时在股票之间的相互依赖和它们的股价在时序上的变化建模<sup>[5]</sup>, 得到一个时序的 Hawkes 超图注意网络, 基于股票盈利对股票进行排序。

### 2.2.1 模型结构

将股票预测表述为一个学习排序问题, 设  $S = \{s_1, s_2, \dots, s_N\}$  为  $N$  只股票的集合, 其中每只股票在交易日  $t$  有一个相关的收盘价  $p^t$  和当天的收益  $r_i^t = \frac{p^t - p^{t-1}}{p^{t-1}}$ , 在给定的任意交易日  $t$ , 存在股票的按照期望收益的最优排序  $Y^t = \{y_1^t > y_2^t \dots > y_N^t\}$ , 排名分数  $Y$  较高的股票在交易日  $t$  有希望获得更高的投资收益。给定长度为  $T$  的窗口股票数据  $[t-T, t-1]$ , 训练一个排序方法, 使其输出一个分数  $y_i^t$ , 根据期望利润对股票进行排序。

模型提取股价时序特征, 提取空间上的股票的超图特征, 最后将时间与空间超图模块进行结合, 捕获股票排名的时间和空间的依赖关系。

### 2.2.2 股价时序特征提取

#### 1. 股价特征提取

历史股票价格已被证明是未来股票趋势的一个强有力的指标<sup>[6]</sup>, 已经被广泛使用在金融领域中。使用前  $T$  个交易日的历史价格信息作为模型的输入特征, 包括当天的收益率, 5 天、10 天、20 天和 30 日均线, 分别代表了每日、每周和每月的趋势。对于每只股票  $s$ , 我们将时间特征进行连接, 形成第  $\tau$  天的股价特征向量  $q_\tau$ , 使用 LSTM 来捕获股价特征  $q_\tau$  中的时间依赖性, 获得第  $\tau$  天的隐藏

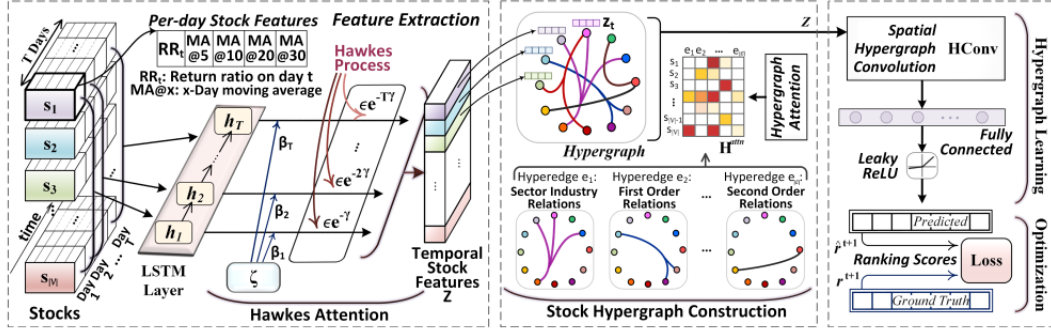


图 2.4 模型结构

状态  $h_t \in \mathbb{R}^d$

$$h_t = LSTM(q_t, h_{t-1}), \quad t - T \leq \tau \leq t - 1$$

其中  $d$  表示隐藏状态的维数。

## 2. 时间注意力机制

每天股票的走势对未来的价格有不同的影响，所以采用一个时间注意力机制  $\zeta(\cdot)$  来学习影响未来价格的关键如日期<sup>[5]</sup>。该机制聚合了时间隐藏状态  $\bar{h}_t = [h_{t-T}, \dots, h_{t-1}] \in \mathbb{R}^{d \times T}$ ，该状态由每天学习到的注意权重  $\beta_t$  装换为整体表示得到，该注意力机制描述为

$$\zeta(\bar{h}_t) = \sum_{\tau} \lambda_{\tau}, \lambda_{\tau} = \beta_{\tau} h_{\tau}, \beta_{\tau} = \frac{\exp(h_{\tau}^T W \bar{h}_t)}{\sum_{\tau} \exp(h_{\tau}^T W \bar{h}_t)}$$

其中  $W$  是一个学习得到的线性变换， $\beta_{\tau}$  表示学习到的注意力权重，用于聚合所有时间特征，同时为更重要的特征分配更高的权重。

## 3. Hawkes 注意力机制

Hawkes 是一个时间点计数过程，它模拟了时间随时间到达的顺序。在某种意义上，每个时间都“激发”了这个过程，即在一段时间内，随后到达的机会增加了。在股票市场中，如发布财报等情况会影响未来的价格，这种影响会随着时间的推移而衰减。Hawkes 过程可以用来模拟历史股票价格并预测未来趋势<sup>[7]</sup>。故使用 Hawkes 注意力机制聚合每日股票的潜在表征  $\lambda_{\tau}$  来增强时间注意力机制  $\zeta(\cdot)$ 。该机制学习对应第  $\tau$  天的激励参数  $\epsilon$  和衰减参数  $\gamma$ ，对于每只股票计算一个时间特征  $z_t$

$$z_t = \sum_{\tau=0, \Delta t_{\tau} \geq 0} (\lambda_{\tau} + \epsilon \max(\lambda_{\tau}, 0) e^{-\gamma \Delta t_{\tau}})$$

其中  $\Delta t_{\tau}$  为当日与过去日  $\tau$  之间的时间差，将所有股票特征  $z_t$  连接形成  $Z \in \mathbb{R}^{N \times d}$ 。

### 2.2.3 股票空间超图构建

#### 1. 股票超图构建

通过超图来建立股票相互依赖的模型，其中超边表示股票之间的高阶关系。构造一个超图  $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{W})$ ，其中每个顶点  $v \in \mathcal{V}$  代表一只股票，每个超边  $e \in \mathcal{E}$  代表一系列相关股票  $\{s_1, s_2, \dots, s_n\}$  的子集。每个超边被赋一个正的权值  $w(e)$ ，所有的权值都存储在对角矩阵  $\mathbf{W} \in \mathbb{R}^{|\mathcal{E}| \times |\mathcal{E}|}$ 。假设当  $\mathbf{W} = \mathbf{I}$  时，所有超边的权值相等。

基于行业关系和 Wiki 关系在股票之间构建超边缘注入领域知识，行业超边为同一行业的股票，根据行业表现，总体上经历相似的价格趋势<sup>[8]</sup>。为了利用这一信号，构建一个连接属于同一行业的股票的超边缘  $e \in \mathcal{E}_{ind}$ 。Wiki 关系超边为考虑基于 Wiki 数据的两种类型的股票之间的企业关系<sup>[9]</sup>，企业关系的第一种类型是一阶关系，定义为  $X \rightarrow^{R1} Y$ ，其中  $R1$  表示 Wiki 数据定义中的股票  $X, Y$  的实体关系。使用这些关系构造一个超边  $e \in \mathcal{E}_1$ ，它由一个源股票和一组通过相同 Wiki 数据关系与源股票相关的目标股票组成。第二种类型是二阶关系，定义为  $X \rightarrow^{R2} Z \leftarrow^{R3} Y$  其中  $Z$  表示通过实体关系  $R2, R3$  连接两个股票  $X, Y$  的实体。在两个股票之间构造一个二阶关系的超边  $e \in \mathcal{E}_2$ 。

将这些关系组合为  $\mathcal{E} = \mathcal{E}_{ind} \cup \mathcal{E}_1 \cup \mathcal{E}_2$  来构造超图  $\mathcal{G}$ ，等价的表示为关联矩阵  $\mathbf{H} \in \mathbb{R}^{|\mathcal{V}| \times |\mathcal{E}|}$ ，其中  $h(v, e)$  定义为

$$h(v, e) = \begin{cases} 1, & v \in e \\ 0, & v \notin e \end{cases}$$

每个顶点  $v$  的度数使用  $d(v)$  获得，并存储在对角矩阵  $\mathbf{D}_v \in \mathbb{R}^{|\mathcal{V}| \times |\mathcal{V}|}$  中

$$d(v) = \sum_{e \in \mathcal{E}} w(e) h(v, e) = \sum_{e \in \mathcal{E}} h(v, e)$$

利用  $\delta(e) = \sum_{v \in \mathcal{V}} h(v, e)$  得到各超边的度  $e$ ，存储在对角矩阵  $\mathbf{D}_e \in \mathbb{R}^{|\mathcal{E}| \times |\mathcal{E}|}$

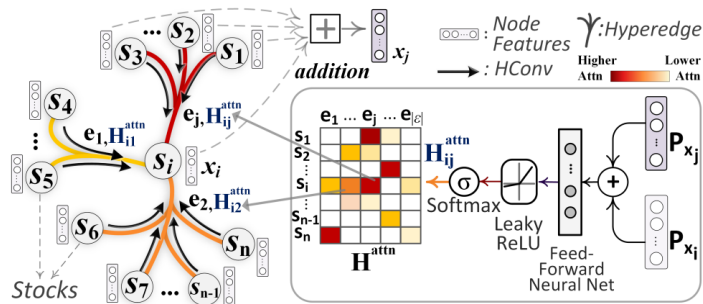


图 2.5 超图卷积

## 2. 超图卷积

为了了解股价变动之间的相互依赖关系，在超图上使用超图卷积。

首先定义一个单一的超图卷积  $HConv(\cdot)$ ，其中第  $l$  个超图卷积层的输入是时间股票特征  $\mathbf{X}^{(l)} \in \mathbb{R}^{|\mathcal{V}| \times F^{(l)}}$ ，其中  $F^{(l)}$  是时间特征的维度。超图卷积利用相邻的股票特征及其在超图  $\mathcal{G}$  中表示的结构关系，将时间特征  $\mathbf{X}^{(l)}$  更新为特征  $\mathbf{X}^{(l+1)} \in \mathbb{R}^{|\mathcal{V}| \times F^{(l+1)}}$ ，其中  $F^{(l+1)}$  是转换后节点的特征维度。

将超图拉普拉斯函数定义为  $\Delta = \mathbf{I} - \mathbf{D}_v^{-1/2} \mathbf{H} \mathbf{W} \mathbf{D}_e^{-1} \mathbf{H}^T \mathbf{D}_v^{-1/2}$ ，得到超图卷积更新规则

$$\mathbf{X}^{(l+1)} = HConv(\mathbf{X}^{(l)}, \mathbf{H}, \mathbf{P})$$

展开后

$$\mathbf{X}^{(l+1)} = ELU(\mathbf{D}_v^{-1/2} \mathbf{H} \mathbf{W} \mathbf{D}_e^{-1} \mathbf{H}^T \mathbf{D}_v^{-1/2} \mathbf{X}^{(l)} \mathbf{P})$$

其中  $\mathbf{P} \in \mathbb{R}^{F^{(l)} \times F^{(l+1)}}$  为可学习矩阵。

## 3. 超图的注意机制

为了捕获每种股票关系对每种股票的时间价格演变的不同影响程度，在关联矩阵  $\mathbf{H}$  上采用了超图注意机制，该机制根据股票的时间特征学习每个与股票相关的超边并进行加权，在股票关系上添加学习机制，从而连接了时间 Hawkes 注意与空间超图卷积。对每个节点  $v_i \in \mathcal{V}$  及其相关的超边  $e_j \in \mathcal{E}$ ，使用股票时间特征  $x_i$  和聚合超边特征  $x_j$  计算关注系数  $H_{ij}^{at}$ ，量化对应关系  $e_j$  对股票的重要性。

将注意力系数定义为单层前馈网络  $\tilde{a}$  的 Softmax

$$H_{ij}^{at} = \frac{\exp(\text{LeakyReLU}(\tilde{a}^T [\mathbf{P}x_i \oplus \mathbf{P}x_j]))}{\sum_{k \in \mathcal{N}_i} \exp(\text{LeakyReLU}(\tilde{a}^T [\mathbf{P}x_i \oplus \mathbf{P}x_k]))}$$

其中  $\oplus$  为拼接， $\mathbf{P}$  为学习到的线性变换， $\mathcal{N}_i$  为  $x_i$  的邻域，它可以使用构造的超图  $\mathcal{G}$  访问，最后将学习到的超图关联矩阵  $\mathbf{H}^{at}$  用于超图卷积。

使用多头架构来稳定训练<sup>[10]</sup>，将  $K$  个独立执行使用富集关联矩阵  $\mathbf{H}^{at}$  应用超图卷积将输出连接

$$\mathbf{X}^{(l+1)} = \oplus_{k=1}^K ELU(\mathbf{D}_v^{-1/2} \mathbf{H}_k^{at} \mathbf{W} \mathbf{D}_e^{-1} \mathbf{H}_k^{atT} \mathbf{D}_v^{-1/2} \mathbf{X}^{(l)} \mathbf{P}_k)$$

其中  $\mathbf{H}_k^{at}$  和  $\mathbf{P}_k$  分别为第  $k$  的执行器的富集关联矩阵和权值矩阵。

## 4. 学习排名与网络优化

使用两个超图卷积  $HConv(\cdot)$ ，在第一层与第二层之间有一个 ELU 激活，将时间股票特征  $\mathbf{Z}$  输入模型的第一层  $\mathbf{X}^{(0)} \in \mathbb{R}^{|\mathcal{V}| \times d}$ ，模型的最后一层  $\mathbf{X}^{(2)} \in \mathbb{R}^{|\mathcal{V}| \times 1}$  输出预测的股票排名  $\hat{r}^{t+1}$

$$\hat{r}^{t+1} = HConv(\oplus_{k=1}^K HConv(\mathbf{Z}, \mathbf{H}^{at}, \mathbf{P}_1), \mathbf{H}^{at}, \mathbf{P}_2)$$

其中  $P_1, P_2$  分别为第一层和第二层的参数矩阵。

使用点回归和两两排序感知损失的组合来优化模型，以最小化预测和实际回报率之间的差异

$$L = \|\hat{r}^{t+1} - r^{t+1}\|^2 + \phi \sum_{i=0}^{|\mathcal{V}|} \sum_{j=0}^{|\mathcal{V}|} \max(0, -(\hat{r}_i^{t+1} - \hat{r}_j^{t+1})(r_i^{t+1} - r_j^{t+1}))$$

其中  $\hat{r}^{t+1}, r^{t+1}$  分别为预测排名与实际排名， $\phi$  为加权参数。

## 2.2.4 结果评估

分别使用 NASDAQ, NYSE, TSE 三个指数的成分股对模型进行评估。

Model	Description	NASDAQ		NYSE		TSE	
		SR $\uparrow$	IRR $\uparrow$	SR $\uparrow$	IRR $\uparrow$	SR $\uparrow$	IRR $\uparrow$
CLF	ARIMA (Wang and Leu 1996)	0.55	0.10	0.33	0.10	0.47	0.13
	A-LSTM (Feng et al. 2019a)	0.97	0.23	0.81	0.14	1.10	0.43
	HGCluster (Luo et al. 2014)	0.06	0.10	0.10	0.11	0.20	0.10
	GCN (Li et al. 2020)	0.75	0.13	0.70	0.10	0.90	0.28
	HATS (Kim et al. 2019)	0.80	0.15	0.73	0.12	0.96	0.31
REG	SFM (Zhang et al. 2017)	0.16	0.09	0.19	0.11	0.08	0.07
	LSTM (Bao et al. 2017)	0.48	0.13	0.13	0.09	0.63	0.20
RL	DQN (Carta et al. 2020)	0.93	0.20	0.72	0.12	1.08	0.31
	iRDPG (Liu et al. 2020)	1.32	0.28	0.85	0.18	1.10 $\dagger$	0.55 $\dagger$
	LSTM (Bao et al. 2017)	0.95	0.22	0.79	0.12	0.73	0.21
RAN	GCN (Kipf et al. 2017)	0.46	0.13	0.72	0.16	0.81	0.27
	RSR-E (Feng et al. 2019b)	1.12	0.26	0.88	0.20	1.07	0.50
	RSR-I (Feng et al. 2019b)	1.34 $^*$	0.39 $^*$	0.95 $^*$	0.21 $^*$	1.08	0.53
	STHAN-SR (Ours)	1.42 $^{* \dagger}$	0.44 $^{* \dagger}$	1.12 $^{* \dagger}$	0.33 $^{* \dagger}$	1.19 $^{* \dagger}$	0.62 $^{* \dagger}$

图 2.6 结果评估

证明了该模型在股票交易中的高回报性以及泛化性。



## 第3章 引入宏观市场因素的金融大数据分析

### 3.1 耦合宏观-行业-微观金融指标的低不确定性股票表征学习

除了关注优化投资组合以外，优化对股票的走势的预测也是非常重要的。

股票的走势预测已经得到了广泛的研究，有一些经典方法侧重于多变量或时间序列之间的相关性建模，但由于数据和模型的不确定性，目前的预测模型主要存在两个问题：

- 在随机股票数据上以端到端方式训练预测模型可能导致过拟合。
- 股票数据与其相关因素的关联分析涉及到数据的不确定性。

为了同时从数据和建模的角度解决这种不确定性，科学家在侧重股价特征以外的特征已经做了许多尝试，例如将考虑新闻事件对投资决策的影响<sup>[11]</sup>。

一个基础但具有挑战性的方法是通过考虑从宏观层面到行业和微观层面的分层拟合以更低的不确定性进行股票表征学习<sup>[12]</sup>。

**Guifeng Wang** 等人提出了一种基于 **copula** 的对比预测编码 (Co-CPC) 方法，Co-CPC 首先模拟某一股票行业与相关的连续多相的宏观经济变量之间的依赖关系，例如宏观变量与不同的时间间隔、规模、分布有关。然后通过引入宏观行业变量模型，以自监督的方式进行股票表征学习，进一步进行股票趋势预测等任务。




图 3.1 一些宏观变量以及其变化的特征

#### 3.1.1 编码器-解码器结构

给定  $m$  个宏观经济指标序列  $\mathbf{Q} = (\mathbf{q}_1, \dots, \mathbf{q}_m)$ ，其中每个指标都有自己的时间区间  $\tau$ ，因此对于一个异构多时间序列，将长度为  $T_i$  的第  $i$  个指标表示为

$$\mathbf{q}_i = [q_{i,1}, \dots, q_{i,t\tau}, \dots, q_{i,T_i}]$$

给定股价的时间序列  $\mathbf{y} = [y_1, \dots, y_T]$  以及其  $d$  维特征（如开盘价、收盘价、最高价等） $\mathbf{X} = [x_1, \dots, x_T] \in \mathbb{R}^{D \times T}$ 。

我们的目标是训练一个编码器函数来表示股票，并使用解码器来进行预测。

$$g_{enc} = \mathbf{F}(\mathbf{Q}_{\leq T}, \mathbf{y}_{\leq T}, \mathbf{X}_{\leq T})$$

$$\hat{y}_{T+1}, \dots, \hat{y}_{T+k} = g_{dec}(g_{enc}(\mathbf{x}_{T+1}, \dots, \mathbf{x}_{T+k}))$$

其中  $g_{enc}$  为编码器函数， $g_{dec}$  为解码器函数， $F(\cdot)$  为训练编码器的函数。

### 3.1.2 宏观行业背景学习

为了处理变量之间的异构性和不对齐的问题，将每个观测序列映射到一个隐藏空间，学习其边界分布<sup>[12]</sup>。然后用一个联结函数将它们结合在一起，得到一个带有系数矩阵  $\mathbf{R}$  的联合分布。最后可以通过一个门函数 (gating function) 来生成对应股票的宏观行业特征。相对于单只股票，宏观行业数据对整个板块的股票影响更稳定且更容易获得。

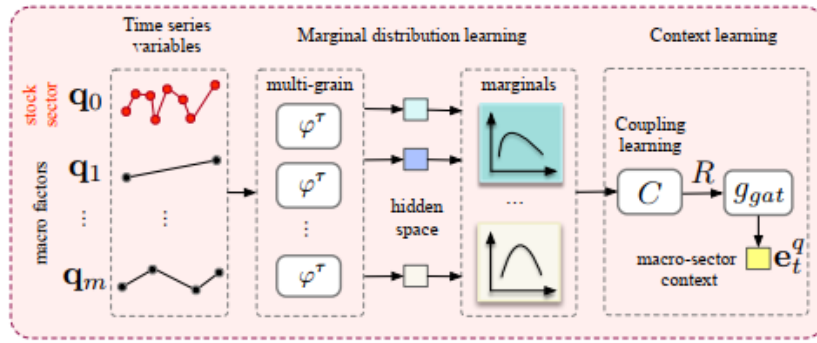


图 3.2 宏观行业背景学习

使用高斯 copula，给定  $m$  个顺序宏观经济指标  $q_1, \dots, q_m$  以及股票行业变量  $q_0$ ，定义如下模型

$$C(\cdot) = \Phi_R(\Phi^{-1}(F_0(q_0)), \dots, \Phi^{-1}(F_m(q_m))) \quad (3.1)$$

其中股票行业变量设为该行业股票每日平均收盘价， $\Phi^{-1}(\cdot)$  为标准正态分布的逆累积分布函数， $\Phi_R(\cdot)$  为多变量正态分布的联合累积分布函数，参数化为平均值为 0 的向量以及协方差矩阵为  $\mathbf{R} \in \mathbb{R}^{(m+1) \times (m+1)}$ 。

现有的学习 copula 函数的估计方法与参数估计和半参数估计方法一样，要求观测数据在每个样本上对齐<sup>[13]</sup>。由于多个时间序列既是时变的，又是异构的，则使用最后时刻的值来进行对齐。

进而采用多粒度的方法来学习不同时间段的状态，探索整个宏观上下文中不同粒度的宏观经济指标的相互作用，采用非线性状态空间模型的形式，其状态



$\mathbf{h}_{i,t}^\tau \in \mathbb{R}^{d_h \times 1}$  根据转换动量  $\varphi^\tau$  对每个时间序列  $\mathbf{q}_i$  进行独立演化

$$\mathbf{h}_{i,t}^\tau = \varphi^\tau(\mathbf{h}_{i,t-1}^\tau, q_{i,t\tau}, \mathbf{p}_i; \theta_h), \quad i = 0, 1, \dots, m$$

$$\mathbf{p}_i = \text{Lookup}(\kappa(t))$$

其中转换动量  $\varphi^\tau$  的输入包含序列变量以及具体时间，其中以嵌入式查找周中某一天和一年中的某一天的值。使用带  $\theta_h$  的多粒度 *LSTM* 参数化转换动量。多粒度意为具有相同时间间隔  $\tau$  的序列具有相同的参数  $\theta_h$ 。

不失一般性，我们假设这些观测值满足高斯分布<sup>[14]</sup>，其均值和方差均来自于  $\mathbf{h}_{i,t}^\tau$ ，可以保证其特殊性

$$\mu_{i,t} = \mathbf{w}_\mu^T \mathbf{h}_{i,t}^\tau$$

$$\sigma_{i,t} = \mathbf{w}_\sigma^T \mathbf{h}_{i,t}^\tau$$

其中  $\mathbf{w}_\mu, \mathbf{w}_\sigma \in \mathbb{R}^{d_h \times 1}$ 。每个时间序列的分布只取决于它们自己的状态  $\mathbf{h}_{i,t}^\tau$ ，但上述两个参数与其他时间序列相关，这有利于后续联合分布学习<sup>[12]</sup>。

基于训练得到参数为  $\beta = \theta_h, \mathbf{w}_\mu, \mathbf{w}_\sigma$  的各个时间序列的边际分布  $\hat{F}$ ，首先计算其序列中每个变量的秩  $\tilde{q}_{i,t}$ ，根据训练得到的边际分布和标准正态分布  $\Phi^{-1}$  的逆 CDF 对每个变量进行变换，其中变换后的第  $i$  个时间序列表示为

$$\mathbf{u}_i = [\Phi^{-1}(\hat{F}_i(\tilde{q}_{i,1}; \beta_i)), \dots, \Phi^{-1}(\hat{F}_i(\tilde{q}_{i,t\tau}; \beta_i)), \dots]$$

所以式 (2.1) 中训练协方差矩阵  $\mathbf{R}$  的损失可以写为 MLE 形式，已知 CDF 是可微的，所以损失可以通过基于随机梯度的方法来训练

$$\mathcal{L}_C = - \sum_{i=0}^m \{ \log \Phi_R(\mathbf{u}_0, \dots, \mathbf{u}_m) + \sum_t \log \hat{f}_i(\tilde{q}_{i,t}) \}$$

其中  $\tilde{f}_i(\cdot)$  是概率密度函数，在训练过程中  $\Phi_R$  需要计算  $\mathbf{R}$  的逆，这可能会导致数值不稳定，使用 *Cholesky* 分解，系数矩阵可以分解为  $\mathbf{R} = \mathbf{L}\mathbf{L}^T$ ， $\mathbf{L}$  是 *Cholesky* 分解的下三角矩阵。

在构建了需要优化的  $\mathcal{L}_C$  以后，还需要构建一个门函数  $g_{gat}$  来将所有指数影响整合，进而得到宏观因素对特定股票的影响。

$$\alpha = g_{gat}(\mathbf{R}) = \text{Sigmoid}(\mathbf{w}_R \mathbf{R} + \mathbf{b}_R)$$

其中  $\mathbf{w}_R, \mathbf{b}_R, \alpha \in \mathbb{R}^{1 \times (m+1)}$  有相同的维数， $t$  时刻具体的宏观行业因素被表示为  $\mathbf{e}_t^q$

$$\mathbf{e}_t^q = \sum_{i=0}^m \alpha_i \mathbf{h}_{i,t}^T$$

### 3.1.3 股票表征学习

因为标记包含的信息较少，为了得到更低损失的宏观和微观耦合，我们使用无监督的方式来训练股票趋势的预测<sup>[12]</sup>。将宏观行业因素  $\mathbf{e}_t^q$  与未来的股票趋势联系起来，形成宏观-行业-微观架构。通过将未来的状态识别为负样本和正样本，将其转换为预测它们是否存在联系。由于模型是在观测数据上训练的，所以无监督架构可以在编码器  $g_{enc}$  上表达股票趋势。由于上下文信息和未来股票走势存

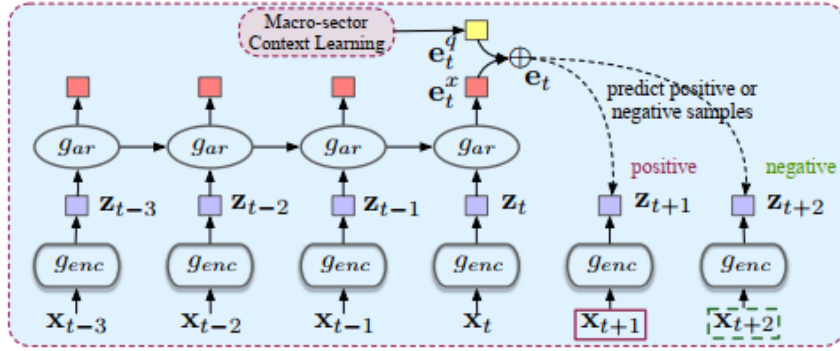


图 3.3 股票表征学习

在联系，更多的上下文信息有利于时间序列预测<sup>[15]</sup>，故基于 CPC 方法计算未来股票的走势  $\mathbf{x}$  和上下文信息  $\mathbf{e}$  之间的互信息  $\mathbf{I}(\mathbf{x}; \mathbf{e})$ ，对其关系进行建模

$$\mathbf{I}(\mathbf{x}; \mathbf{e}) = \sum_{\mathbf{x}, \mathbf{e}} p(\mathbf{x}, \mathbf{e}) \log \frac{p(\mathbf{x}|\mathbf{e})}{p(\mathbf{x})}$$

CPC 模型中的上下文信息也被成为“慢特征”，在该模型中，“慢特征”不仅体现在股票表征上，还体现在宏观行业背景中。通过最大化互信息  $\mathbf{I}(\mathbf{x}; \mathbf{e})$ ，可以更好的模拟当前上下文对特定股票趋势的影响，将宏观-行业-微观信息由 MLP 连接

$$\mathbf{e}_t = MLP([\mathbf{e}_t^q, \mathbf{e}_t^x])$$

为了得到微观上下文信息，首先采用非线性编码器  $g_{enc}$  将特征  $\mathbf{x}_t$  映射到表征序列  $\mathbf{z}_t = g_{enc}(\mathbf{x}_t)$ ，使用自回归模型  $g_{ar}$  综合所有的  $\mathbf{z}_{\leq t}$  得到一个股票的上下文表征  $\mathbf{e}_t^x = g_{ar}(\mathbf{z}_{\leq t})$ ，其中  $\mathbf{e}_t^x \in \mathbb{R}^{1 \times d_x}$ 。

与 CPC 方法类似，不使用  $p_k(\mathbf{x}_{t+k}|\mathbf{e}_t)$  直接预测  $\mathbf{x}_{t+k}$ ，而是对密度比进行建模，该密度比将  $\mathbf{x}_{t+k}$  和  $\mathbf{e}_t$  的联系设为

$$f_k(\mathbf{x}_{t+k}, \mathbf{e}_t) \propto \frac{p(\mathbf{x}_{t+k}|\mathbf{e}_t)}{p(\mathbf{x}_{t+k})}$$

其中  $\propto$  表示“成比例”，采用对数双线性模型作为密度比函数  $f_k$

$$f_k(\mathbf{x}_{t+k}, \mathbf{e}_t) = \exp(\mathbf{z}_{t+k}^T \mathbf{W}_k \mathbf{e}_t)$$

线性变换  $\mathbf{W}_k \mathbf{e}_t$  可以用于预测，每个时刻  $k$  都具有不同的  $\mathbf{W}_k$ 。使用上式来预测上下文信息与未来股票趋势有联系的概率，通过这种方式，可以区分与之前的上下文信息不一致的未来股票趋势。

CPC 中的损失函数基于噪声对比估计 (NCE) 技术<sup>[16]</sup>，给定股票序列  $\mathbf{X} = \{\mathbf{X}_1, \dots, \mathbf{X}_n\}$  并且每只股票表征序列为  $\mathbf{X}_j = [\mathbf{x}_{j,1}, \dots, \mathbf{x}_{j,T}]$ ，损失函数为

$$\mathcal{L}_N = -\mathbb{E}_{\mathbf{X}}[\log \frac{f_k(\mathbf{x}_{t+k}, \mathbf{e}_t)}{\sum_{\mathbf{x}_j \in \mathbf{X}} f_k(\mathbf{x}_j, \mathbf{e}_t)}]$$

由于第一部分的参数也前馈到股票表征学习中，通过与方程中基于 **copula** 损失的模型集成到式 2.1 中。将预测任务的总损失最小化为

$$\mathcal{L} = \frac{1}{2\gamma_1^2} \gamma_C + \frac{1}{2\gamma_2^2} \mathcal{L}_N + \log \gamma_1 \gamma_2$$

其中  $\gamma_1, \gamma_2$  为用于平衡两个损失的参数，通过 SGD 来优化损失。

### 3.1.4 结果评估

在 **ACL18**<sup>[17]</sup> 和 **KDD17**<sup>[18]</sup> 两个数据集中对模型进行评估，使用标准准确度与马修斯相关系数作为评价指标，最终得到的结果为

Method	ACL18		KDD17	
	Acc.	MCC	Acc.	MCC
<b>StockNet</b>	54.96	0.00165	51.93	0.0335
<b>LSTM</b>	53.18	0.0674	51.62	0.0183
<b>ALSTM</b>	54.90	0.1403	51.94	0.0261
<b>Adv-ALSTM</b>	57.20	0.1483	53.05	0.0523
<b>CPC</b>	58.14	0.1631	54.47	0.0746
<b>Co-CPC</b>	<b>58.90</b>	<b>0.1771</b>	<b>58.81</b>	<b>0.1643</b>
<b>StockNet</b>	58.23	0.0808	-	-
<b>LSTM</b>	56.82	0.1375	-	-
<b>CPC</b>	59.11	0.1817	-	-
<b>Co-CPC</b>	<b>61.62</b>	<b>0.2316</b>	-	-

图 3.4 模型评估

证明了该模型在短期和长期股票走势预测中的有效性。

## 3.2 嵌入市场条件的风险收益平衡投资管理的深度强化学习方法

**Zhicheng Wang** 等人提出了一种深度强化学习方法来优化投资策略。为了解决风险收益平衡问题，模型将宏观市场条件作为指标，动态调整多空资金的比例，降低市场波动的风险，并以负的最大回撤作为回报函数<sup>[19]</sup>。

模型中还存在一个评估单个资产的单元，以价格上涨速度为回报函数，从历史数据中学习动态模式。

### 3.2.1 模型结构

该模型模型分为市场评估单元与资产评估单元，综合两个单元的评分调节投资组合的多空比，以获得更稳定且更高的收益。

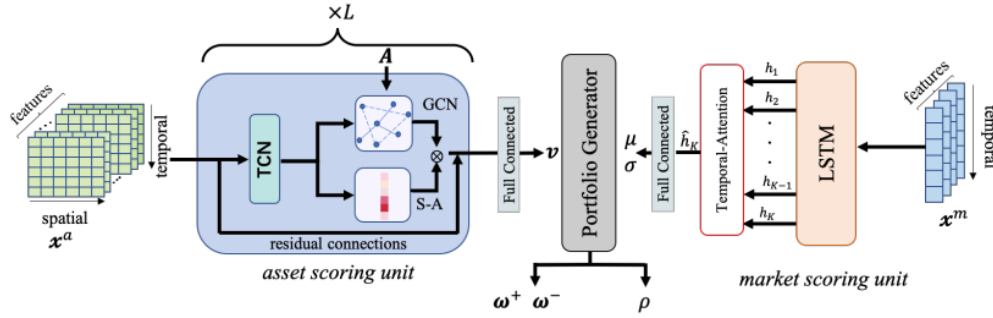


图 3.5 模型结构

### 3.2.2 资产评估单元

该单元包括时间卷积层、空间注意机制以及图卷积层，用于捕获股票之间的空间和时间相互关系。

#### 1. 时间卷积层

使用扩展时间卷积层 (TCN)<sup>[20]</sup> 来处理长范围序列中的时间关系，与基于 RNN 的方法相比，它便于并行计算，减轻了梯度爆炸和消失的问题<sup>[19]</sup>。

定义第  $l$  块的输入为

$$\mathbf{H}^{l-1} \in \mathbb{R}^{C \times N \times K_{l-1}}$$

其中  $C$  是隐藏特征的维度， $N$  是股票的数量， $K_{l-1}$  是第  $l-1$  块的时间长度。在沿时间维度进行 TCN 运算后，使用  $\hat{\mathbf{H}}^l \in \mathbb{R}^{C \times N \times K_l}$  作为该层的输出。

#### 2. 空间注意机制

为了模拟股票的短期空间属性，采用注意机制自适应搜索股票之间的相关性。在每个时间步为每个向量分配不同的权重，权重反映了不同股票的相关性。

给定 TCN 层的最终输出  $\hat{\mathbf{H}}^l \in \mathbb{R}^{C \times N \times K_l}$ ，计算权重向量

$$\hat{\mathbf{S}}^l = \mathbf{V}_s \text{Sigmoid}((\hat{\mathbf{H}}^l \mathbf{W}_1) \mathbf{W}_2 (\mathbf{W}_3 \hat{\mathbf{H}}^{l(1,2)T} + \mathbf{b}_s))$$

其中  $\mathbf{W}_1 \in \mathbb{R}^{K_l}$ ， $\mathbf{W}_2 \in \mathbb{R}^{C \times K_l}$ ， $\mathbf{W}_3 \in \mathbb{R}^C$ ，并且  $\mathbf{V}_s \in \mathbb{R}^{N \times N}$  为超参数， $\mathbf{b}_s \in \mathbb{R}^{N \times N}$  为偏置向量，上标  $\mathbf{T}(1,2)$  表示前两个维度的转置。

将结果使用 Softmax 进行归一化

$$S_{i,j}^l = \frac{\exp(\hat{S}_{i,j}^l)}{\sum_{v=1}^N \exp(\hat{S}_{i,v}^l)}$$

表示节点  $i, j$  之间的相关性。

### 3. 图卷积层

因为个股趋势具有波动性，所以考虑使用行业整体表现来反映未来的经济形式和金融热点趋势。使用图卷积网络（GCNs）对长期走势进行建模以提升模型稳定性。通过使用 GCNs 可以使用消息传递来捕获图中节点的依赖性，从而将边缘和邻域信息集成到状态表示中。

使用以下方法来表示股票之间的结构信息<sup>[19]</sup>：

- 股票行业类型
- 股票收益之间的相关性
- 股票收益之间的偏相关性
- 因果关系，通过 PC 算法识别出股票之间的因果结构<sup>[21]</sup>

对股票行业进行单一分类可能会遗漏某些依赖关系，例如亚马逊被认为是零售贸易，但它也受益于互联网的红利。为了避免这种问题，将图卷积层定义为<sup>[22]</sup>

$$\mathbf{Z}^l = \sum_{q=0}^Q \tilde{\mathbf{A}}^q \hat{\mathbf{H}}^l \boldsymbol{\Theta}_{1,q} + \tilde{\mathbf{A}}_c \hat{\mathbf{H}}^l \boldsymbol{\Theta}_2$$

其中  $\hat{\mathbf{H}}^l$  为第  $l$  块输入信号， $\tilde{\mathbf{A}} = \mathbf{A} / \text{rowsum}(\mathbf{A})$ ，并且  $\boldsymbol{\Theta}_1, \boldsymbol{\Theta}_2 \in \mathbb{R}^{K_l \times K_l}$  是 GCN 中的可学习参数。 $\tilde{\mathbf{A}}_c$  被用于捕获与  $\text{Softmax}(\text{ReLU}(\mathbf{E}\mathbf{E}^T))$  的相关性，其中  $\mathbf{E} \in \mathbb{R}^N$  作为科学性参数，其被随机初始化且通过梯度下降进行学习得到， $Q$  是平衡  $\tilde{\mathbf{A}}$  和  $\tilde{\mathbf{A}}_c$  的超参数。

对于具有相关性、偏相关性和因果关系特征的结构信息，图卷积层表示为

$$\mathbf{Z}^l = \sum_{q=0}^Q \tilde{\mathbf{A}} \hat{\mathbf{H}}^l \boldsymbol{\Theta}_1$$

即省略了上式的第二部分，因为依赖性信息已经从数据中统计得到了。为了同时整合长期和短期的相关性并调整权重矩阵，将  $\mathbf{Z}^l$  与空间注意权值  $\mathbf{S}^l$  结合，将第  $l$  块的最终输出描述为

$$\mathbf{H}^l = \mathbf{S}^l \times \mathbf{Z}^l \oplus \mathbf{H}^{l-1}$$

其中  $\oplus$  表示残差连接，最后使用全连接层将隐藏状态  $\mathbf{H}^L$  转换为资产评分

$$v = \text{Sigmoid}(\mathbf{W}_L \mathbf{H}^L + \mathbf{b}_L)$$

### 3.2.3 市场评估单元

金融数据由于随机博弈和突发事件而包含大量不可预测的不确定性<sup>[23]</sup>。所以根据历史观察准确判断股票涨跌是不可能的，在许多情况下顺序市场是更好的投资策略。当股市下跌时，经验丰富的投资者往往花更多的钱做空，反之，其更愿意做多。

市场评估单元以市场情绪作为输入，以动态调整投资组合。该评估单元首先使用长短期记忆网络（LSTM）递归提取输入  $\mathcal{X}^m$

$$\mathbf{h}_k = LSTM(\mathbf{h}_{k-1}, \mathbf{x}_k^m), k \in [1, K]$$

其中  $\mathbf{h}_k$  表示 LSTM 在第  $k$  步编码的隐藏状态。最后一个隐藏状态  $\mathbf{h}_K$  可以看作是输入信号的全局表示。但是前期的信息可能在很长一段时间内无法有效建模，受注意力机制在 NLP 中成功应用的启发，采用一种时间注意力机制来自适应地建模非线性关系<sup>[19]</sup>，注意权重计算为

$$e_k = \mathbf{V}_e^T \tanh(\mathbf{U}_1[\mathbf{h}_k; \mathbf{h}_K] + \mathbf{U}_2 \mathbf{x}_k^m), \alpha_k = \frac{\exp(e_k)}{\sum_{i=1}^K \exp(e_i)}$$

其中  $\mathbf{V}_e \in \mathbb{R}^C, \mathbf{U}_1 \in \mathbb{R}^{C \times 2C}, \mathbf{U}_2 \in \mathbb{R}^{C \times C}$  是需要学习的参数，则最后一个隐藏状态重新计算为

$$\hat{\mathbf{h}}_K = \sum_{i=1}^K \alpha_i \mathbf{h}_i$$

进一步用  $\mu, \sigma$  表示

$$\mu, \sigma = \mathbf{U}_m \hat{\mathbf{h}}_K + \mathbf{m}$$

### 3.2.4 投资组合生成器

在获得资产评分  $v$ ，使用 Softmax 函数将  $v$  转换为投资组合权重，根据  $v$  的降序对所有股票进行排序，然后选择排名前  $G$  的股票作为做多组  $\mathcal{V}^+$ ，选择排名后  $G$  的股票作为做空组  $\mathcal{V}^-$ 。计算多头与空头投资组合向量  $\omega^+, \omega^-$

$$\omega_i^+ = \begin{cases} \frac{\exp(v_i)}{\sum_{j \in \mathcal{V}^+} \exp(v_j)}, & i \in \mathcal{V}^+ \\ 0 & i \notin \mathcal{V}^+ \end{cases} \quad \omega_i^- = \begin{cases} \frac{\exp(1-v_i)}{\sum_{j \in \mathcal{V}^-} \exp(1-v_j)}, & i \in \mathcal{V}^- \\ 0 & i \notin \mathcal{V}^- \end{cases}$$

由市场评估单元生成的  $\rho$  可以视为在连续动作空间  $\mathcal{A}^m \in [0, 1]$  选择的一个值，假设随机变量  $\tilde{\rho}$  遵循正态分布  $\tilde{\rho} \sim N(\mu, \sigma^2)$ ，其中  $\mu, \sigma$  为市场评估单元。在训练阶段基于采样值  $\tilde{\rho}$  进行优化，在测试阶段使用  $\mu$  作为  $\tilde{\rho}$  进行优化，最后将  $\tilde{\rho}$  映射到范围  $[0, 1]$  空间  $\rho = \text{clamp}(\tilde{\rho})$

设  $t$  时持有现金  $C_{t-1}^0$ ，上一时刻多头股票的交易量  $\mathbf{b}_{t-1}^+ = \{b_{t-1,1}^+, \dots, b_{t-1,N}^+\}$ ，空头股票总量  $\mathbf{b}_{t-1}^-$ ，已知多头与空头的投资组合向量  $\omega_t^+, \omega_t^-$ ，用于空头的总资产比例  $\rho_t$ ，则

- 根据买入量  $b_{t-1}^+$  卖出所有多头股票，获得现金
- 购买在  $t-1$  所在周期借入的股票  $b_{t-1}^-$  并归还
- 根据  $\rho_t$  与空头组合  $\omega_t^-$  借入股票并立刻卖出
- 根据多头组合  $\omega_t^+$  买入股票

### 3.2.5 结果评估

分别使用 DJIA, HSI, CSI100 的数据对模型进行评估

Dataset	DJIA						HSI						CSI100					
Models	ARR(%)	AVol	ASR	SoR	MDD(%)	CR	ARR(%)	AVol	ASR	SoR	MDD(%)	CR	ARR(%)	AVol	ASR	SoR	MDD(%)	CR
Market	4.17	<b>0.158</b>	0.264	0.787	49.93	0.084	4.53	0.222	0.204	0.707	56.37	0.080	10.49	0.255	0.411	2.542	39.54	0.265
BLSW	6.57	0.279	0.235	1.112	72.72	0.090	-10.01	0.294	-0.343	-1.213	90.97	-0.111	28.25	0.494	0.572	4.205	29.29	0.964
CSM	-3.57	0.248	-0.144	-0.422	88.31	-0.040	7.66	0.295	0.260	0.858	53.25	0.144	19.17	0.411	0.466	1.753	61.73	0.311
EIIE	9.96	0.185	0.537	1.707	45.98	0.217	<b>23.40</b>	0.363	0.645	2.523	50.26	0.466	25.07	<b>0.235</b>	1.067	3.949	29.04	0.863
AS	9.13	<b>0.158</b>	0.579	2.187	26.66	0.343	14.51	<b>0.183</b>	0.793	3.007	17.39	0.834	21.85	0.241	0.922	4.012	19.93	1.096
DT-NS	10.21	0.163	0.628	2.448	26.33	0.388	19.03	0.211	0.902	4.462	19.93	0.955	30.48	0.286	1.066	5.438	<b>16.24</b>	1.877
DT-NM	11.49	0.180	0.638	2.507	31.24	0.368	20.72	0.223	0.930	4.572	20.17	1.027	<b>35.67</b>	0.324	<b>1.100</b>	<b>6.059</b>	18.13	<b>1.967</b>
DT	<b>12.35</b>	0.172	<b>0.718</b>	<b>2.782</b>	<b>22.61</b>	<b>0.546</b>	21.85	0.209	<b>1.044</b>	<b>5.140</b>	<b>17.11</b>	<b>1.277</b>	-	-	-	-	-	-

图 3.6 模型评估

证实了该模型在复杂的金融形式如金融危机等的背景下，仍能将财富长期积累到一个较高水平。

## 第 4 章 探索性思考

虽然目前许多模型在解决数据与模型不确定性的工作中取得了很大的进展，但仅分析上述四篇文章，在引入宏观市场因素后，模型仍有可能在具有某一系列特征趋势的数据上过拟合；若剔除市场因素，模型会因为未引入外部特征而造成信息缺失；此外，这些模型虽然建立了股票与股票，股票与市场等对象之间的关系，但为建立的关系均为不可解释的，使得无法深入对某一联系的研究。



## 参 考 文 献

- [1] FABOZZI F J, MARKOWITZ H M, GUPTA F. Portfolio selection[J]. Handbook of finance, 2008, 2.
- [2] BLITZ D, HUIJ J, MARTENS M. Residual momentum[J]. Journal of Empirical Finance, 2011, 18(3): 506-521.
- [3] IMAJO K, MINAMI K, ITO K, et al. Deep portfolio optimization via distributional prediction of residual factors[A]. 2020. arXiv: 2012.07245.
- [4] PARTOVI M H, CAPUTO M, et al. Principal portfolios: Recasting the efficient frontier[J]. Economics Bulletin, 2004, 7(3): 1-10.
- [5] SAWHNEY R, AGARWAL S, WADHWA A, et al. Stock selection via spatiotemporal hypergraph attention network: A learning to rank approach[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 35. 2021: 497-504.
- [6] JEANBLANC M, YOR M, CHESNEY M. Mathematical methods for financial markets[M]. Springer Science & Business Media, 2009.
- [7] BACRY E, MASTROMATTEO I, MUZY J F. Hawkes processes in finance[J]. Market Microstructure and Liquidity, 2015, 1(01): 1550005.
- [8] LIVINGSTON M. Industry movements of common stocks[J]. The Journal of Finance, 1977, 32(3): 861-874.
- [9] VRANDEČIĆ D, KRÖTZSCH M. Wikidata: a free collaborative knowledgebase[J]. Communications of the ACM, 2014, 57(10): 78-85.
- [10] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [11] ZHANG X, ZHANG Y, WANG S, et al. Improving stock market prediction via heterogeneous information fusion[J]. Knowledge-Based Systems, 2018, 143: 236-247.
- [12] WANG G, CAO L, ZHAO H, et al. Coupling macro-sector-micro financial indicators for learning stock representations with less uncertainty[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 35. 2021: 4418-4426.
- [13] CHOROŚ B, IBRAGIMOV R, PERMIAKOVA E. Copula estimation[C]//Copula Theory and Its Applications: Proceedings of the Workshop Held in Warsaw, 25-26 September 2009. Springer, 2010: 77-91.
- [14] SALINAS D, BOHLKE-SCHNEIDER M, CALLOT L, et al. High-dimensional multivariate forecasting with low-rank gaussian copula processes[J]. Advances in neural information processing systems, 2019, 32.

- [15] WISKOTT L, SEJNOWSKI T J. Slow feature analysis: Unsupervised learning of invariances [J]. *Neural computation*, 2002, 14(4): 715-770.
- [16] GUTMANN M, HYVÄRINEN A. Noise-contrastive estimation: A new estimation principle for unnormalized statistical models[C]//*Proceedings of the thirteenth international conference on artificial intelligence and statistics. JMLR Workshop and Conference Proceedings*, 2010: 297-304.
- [17] XU Y, COHEN S B. Stock movement prediction from tweets and historical prices[C]//*Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. 2018: 1970-1979.
- [18] ZHANG L, AGGARWAL C, QI G J. Stock price prediction via discovering multi-frequency trading patterns[C]//*Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining*. 2017: 2141-2149.
- [19] WANG Z, HUANG B, TU S, et al. Deeptreader: a deep reinforcement learning approach for risk-return balanced portfolio management with market conditions embedding[C]//*Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 35*. 2021: 643-650.
- [20] YU F, KOLTUN V. Multi-scale context aggregation by dilated convolutions[A]. 2015.
- [21] SPIRITES P, GLYMOUR C N, SCHEINES R. Causation, prediction, and search[M]. MIT press, 2000.
- [22] WANG J, ZHANG Y, TANG K, et al. Alphastock: A buying-winners-and-selling-losers investment strategy using interpretable deep reinforcement attention networks[C]//*Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*. 2019: 1900-1908.
- [23] DENG Y, BAO F, KONG Y, et al. Deep direct reinforcement learning for financial signal representation and trading[J]. *IEEE transactions on neural networks and learning systems*, 2016, 28(3): 653-664.

## 致 谢

在这个学期，我选修了数据挖掘课程，从中学到了很多新知识和技能，提升了我对数据挖掘和金融大数据分析领域的兴趣。

在这门课程中，我学会了如何使用爬虫获取网络上的数据，如何使用 Python 进行数据分析和可视化，如何发现数据中的规律和趋势，如何利用数据解决实际问题。这些知识和技能让我对未来的学习和工作有了更多的期待和信心。

在此，感谢老师和助教们，他们给了我很多帮助和启发，在此深表谢意。